

BÁO CÁO BÀI TẬP LỚN

Big Data Job Market

Xây dựng hệ thống thu thập và phân tích dữ liệu thị trường lao động từ TOPCV

IT4931 – Lưu trữ và xử lý dữ liệu lớn
GVHD: TS. Trần Việt Trung

Nhóm 09:
Phạm Anh Khôi 20230043
Trần Tuấn Minh 20230051
Nguyễn Phúc Huy Hoàng 20235087
Nguyễn Bá Đức Anh 20235004
Trần Gia Định 20235036

Dữ liệu và bài toán

Nguồn dữ liệu

Tin tuyển dụng từ TopCV: tiêu đề, công ty, địa điểm, mức lương, kinh nghiệm, kỹ năng, mô tả công việc, yêu cầu và quyền lợi.

Đặc điểm dữ liệu

Dữ liệu không đồng nhất, nhiều trường nằm trong văn bản tự do; các lần crawl có thể tạo bản ghi lặp nên cần lưu trữ có truy vết và loại trùng theo job_id

Vấn đề cần xử lý

Cần lưu trữ dữ liệu thô để truy vết, chuẩn hóa dữ liệu qua nhiều tầng, loại trùng theo định danh tin tuyển dụng và tạo dữ liệu sạch phục vụ phân tích.

Từ bảng thô khó trả lời nhanh:

Thành phố nào có nhu cầu tuyển dụng cao?

Nhóm ngành và kỹ năng nào xuất hiện nhiều?

Mặt bằng lương công khai tập trung ở khoảng nào?

Dữ liệu mới có thể được cập nhật gần thời gian thực ra sao?

Mục tiêu: Xây dựng pipeline Big Data để thu thập, lưu trữ phân tầng, xử lý batch và streaming, sau đó lập chỉ mục phục vụ truy vấn và trực quan hóa.


Vì sao cần hệ thống Big Data?

Dữ liệu tuyển dụng từ TopCV là dữ liệu web bán cấu trúc, có nhiều trường nằm trong văn bản tự do như mô tả công việc, yêu cầu, quyền lợi và mức lương.

Nếu chỉ crawl và lưu vào một bảng thô, hệ thống khó truy vết dữ liệu gốc, khó tái xử lý khi logic ETL thay đổi và khó phục vụ dashboard ổn định.

Phân tích lịch sử cần batch layer để làm sạch, chuẩn hóa, loại trùng và tạo dữ liệu Gold. Trong khi đó, dữ liệu mới cần speed layer để cập nhật gần thời gian thực.

Vì vậy, hệ thống cần một pipeline Big Data có đủ các tầng: lưu trữ phân tán, xử lý batch, xử lý streaming, điều phối workflow và serving layer cho truy vấn/dashboard.



Thông điệp chính: hệ thống biến dữ liệu tuyển dụng rời rạc từ TopCV thành dữ liệu phân tích có thể lưu trữ, tái xử lý, cập nhật gần thời gian thực và trực quan hóa.

Mục tiêu hệ thống

1. Thu thập & lưu trữ

Crawler thu thập tin tuyển dụng từ TopCV và lưu dữ liệu gốc để có thể truy vết, kiểm tra và tái xử lý khi cần.

2. Xử lý batch theo Medallion

Spark Batch chuyển dữ liệu qua các lớp Raw → Bronze → Silver → Gold, thực hiện làm sạch, chuẩn hóa và loại trùng.

3. Cập nhật dữ liệu mới

Kafka và Spark Structured Streaming xử lý dữ liệu mới theo micro-batch, tạo dữ liệu sạch và các chỉ số gần thời gian thực.


4. Phục vụ truy vấn & dashboard

Elasticsearch lưu dữ liệu batch/realtime dưới dạng index; Kibana trực quan hóa thị trường tuyển dụng, kỹ năng, lương và dữ liệu mới.



Kết quả mong muốn: dữ liệu tuyển dụng được lưu trữ có truy vết, xử lý lặp lại được, truy vấn nhanh và hiển thị trực quan trên dashboard.

Kiến trúc tổng thể



Mô hình triển khai

hdfs	HDFS NameNode / DataNode	Lưu Raw, Bronze, Silver, Gold và model artifact
kafka	Strimzi Kafka	Message broker cho jobs_raw, jobs_clean, jobs_dead_letter
spark	Spark Submit Jobs / CronJobs	Chạy batch ETL, Spark Structured Streaming và các job xử lý dữ liệu
search	Elasticsearch/Kibana	Serving layer và dashboard
airflow	Webserver/Scheduler	Điều phối workflow, kiểm tra service và tạo Kubernetes Job từ các CronJob

Airflow không trực tiếp xử lý dữ liệu; Airflow kích hoạt và giám sát các job đã được đóng gói trong Kubernetes.

Mô hình triển khai

Namespace	Type	Workload	Container
airflow	Deployment	airflow-postgres	postgres
airflow	Deployment	airflow-scheduler	airflow-scheduler
airflow	Deployment	airflow-webserver	airflow-webserver
hdfs	StatefulSet	hdfs-datanode	datanode
hdfs	StatefulSet	hdfs-namenode	namenode
kafka	Deployment	my-cluster-entity-operator	topic-operator
kafka	Deployment	my-cluster-entity-operator	user-operator
kafka	Deployment	strimzi-cluster-operator	strimzi-cluster-operator
kafka	StrimziPod	my-cluster-dual-role-0	kafka
search	Deployment	kibana	kibana
search	StatefulSet	elasticsearch	elasticsearch
spark	CronJob	batch-etl-bronze-to-silver	spark-submit
spark	CronJob	batch-etl-crawl-jobs	batch-crawler
spark	CronJob	batch-etl-gold-to-elasticsearch	spark-submit
spark	CronJob	batch-etl-raw-to-bronze	spark-submit
spark	CronJob	batch-etl-silver-to-gold	spark-submit
spark	CronJob	batch-etl-train-salary-model	spark-submit
spark	Job	speed-real-crawler-producer	speed-crawler-producer
spark	Job	speed-stream-es-submit	spark-submit

PS F:\IT4931- Lưu trữ và xử lý dữ liệu lớn\bigdata-job-market> █


Các workload và container được cấu hình trong hệ thống Kubernetes(Minikube)

Mô hình triển khai

```
infra > search > ! kibana-service.yaml
1  # Kubernetes Service for Kibana UI.
2  #
3  # Local access:
4  #   kubectl port-forward svc/kibana 5601:5601 -n search
5  ---
6  apiVersion: v1
7  kind: Service
8  metadata:
9    name: kibana
10   namespace: search
11  spec:
12    type: ClusterIP
13    selector:
14      app: kibana
15    ports:
16      - name: http
17        port: 5601
18        targetPort: 5601
19
```

Minh họa cấu hình triển khai các thành phần trên Kubernetes(Minikube)

Thiết kế dữ liệu: Medallion




Raw bảo toàn dữ liệu nguồn để có thể tái xử lý.
Bronze tối ưu lưu trữ và đọc dữ liệu bằng Parquet.
Silver là lớp dữ liệu sạch sau chuẩn hóa và loại trùng.
Gold là lớp dữ liệu phục vụ phân tích và trực quan hóa.

Batch Pipeline & Airflow

DAGs

All 3 Active 0 Paused 3 Running 0 Failed 0


DAG	Owner	Runs	Schedule
job_market_batch_pipeline batch job-market kubernetes spark	job-market	6 1	0 2 * * *
job_market_speed_layer_bootstrap elasticsearch job-market kafka spark speed-layer	job-market	21	None
job_market_speed_real_crawler crawler job-market kafka speed-layer	job-market	21 1	* / 20 * * * *



3 DAG chính

job_market_batch_pipeline
job_market_speed_layer_bootstrap
job_market_speed_real_crawler

Batch DAG




Airflow dùng CronJob Kubernetes như template, tạo one-off Job, chờ hoàn thành và thu log khi lỗi.

Batch Pipeline & Airflow

```
with DAG(  
    dag_id="job_market_batch_pipeline",  
    description="Batch pipeline: Crawl -> Raw -> Bronze -> Silver -> Gold -> Elasticsearch",  
    default_args=DEFAULT_ARGS,  
    start_date=pendulum.datetime(2026, 1, 1, tz=TZ),  
    schedule="0 2 * * *",  
    catchup=False,  
    tags=["job-market", "batch", "spark", "kubernetes"],  
) as dag:
```

Cấu hình lịch chạy DAG trên Airflow

Speed Layer: Kafka + Spark Structured Streaming



Speed Layer & Airflow

```
with DAG(  
    dag_id="job_market_speed_real_crawler",  
    description="Scheduled real TopCV speed crawler producer: TopCV -> Kafka jobs_raw",  
    default_args=DEFAULT_ARGS,  
    start_date=pendulum.datetime(2026, 1, 1, tz=TZ),  
    schedule="*/20 * * * *",  
    catchup=False,  
    max_active_runs=1,  
    tags=["job-market", "speed-layer", "crawler", "kafka"],  
) as dag:
```

Cấu hình lịch chạy DAG trên Airflow

Mô hình học máy: dự đoán lương

Tập huấn luyện


Sử dụng các tin tuyển dụng ở lớp Silver có lương công khai để tạo nhãn huấn luyện từ khoảng lương trung bình.

Đặc trưng

Khai thác các trường đã chuẩn hóa như tiêu đề, kỹ năng, kinh nghiệm, địa điểm, công ty và hình thức làm việc.

Serving rule

Không ghi đè lương công khai. Mô hình chỉ bổ sung lương tham khảo cho các tin có lương gốc là “Thoả thuận” hoặc thiếu khoảng lương rõ ràng.



Dashboard sử dụng kết quả này như một bước làm giàu dữ liệu, giúp các tin không công khai lương vẫn có khoảng lương tham khảo để phân tích.

Serving Layer: Elasticsearch

	health	status	index	pri	rep	docs.count
1	yellow	open	gold-jobs-flat	1	1	5424
2	yellow	open	realtime_job_counts_10m_v1	1	1	397
3	yellow	open	realtime_jobs_v1	1	1	669
4	yellow	open	realtime_salary_bins_hourly_v1	1	1	277
5	yellow	open	realtime_skill_counts_hourly_v1	1	1	4775
6	yellow	open	realtime_top_skills_hourly_v1	1	1	231
7	yellow	open				

Batch index

gold-jobs-flat lưu dữ liệu Gold sau xử lý batch. Index này phục vụ các dashboard tổng quan thị trường, kỹ năng, địa điểm và lương công khai.

Realtime indexes


Các index realtime_* lưu dữ liệu mới và các bảng tổng hợp gần thời gian thực như số job theo cửa sổ thời gian, top kỹ năng theo giờ và phân bố lương realtime.

Kibana-ready

Tách riêng index job-level và index aggregate giúp dashboard truy vấn nhanh hơn, không cần tổng hợp lại từ toàn bộ dữ liệu gốc.

Elasticsearch đóng vai trò điểm giao giữa Spark ETL/Streaming và dashboard trực quan hóa.

Kibana Dashboard: Tổng quan thị trường



Insight chính


Nhu cầu tuyển dụng tập trung mạnh ở các đô thị lớn, đặc biệt là Hà Nội và TP. Hồ Chí Minh.

Nhóm ngành IT - Phần mềm nổi bật về số lượng tin tuyển dụng, cho thấy đây là nhóm nhu cầu chính trong tập dữ liệu.

Các kỹ năng được nhắc đến nhiều không chỉ là kỹ năng chuyên môn, mà còn gồm giao tiếp, giải quyết vấn đề và làm việc nhóm.


Dashboard giúp trả lời nhanh: thị trường đang tuyển nhiều ở đâu, ngành nào nổi bật và kỹ năng nào được yêu cầu nhiều.

Kibana Dashboard: Insight lương



Lương công khai

Phần lớn tin có lương công khai tập trung ở khoảng 10–20 triệu. Dashboard sử dụng median theo nhóm ngành và thành phố để giảm ảnh hưởng của các giá trị ngoại lệ.



Làm giàu dữ liệu lương

Các tin có lương gốc “Thoả thuận” được bổ sung lương tham khảo ở Gold layer. Phân bố lương ước lượng chủ yếu nằm trong các khoảng 10–20 và 20–30 triệu.

Bài học và kết luận

1. Thu thập dữ liệu

Raw + metadata + job_id giúp truy vết, loại trùng và tái xử lý dữ liệu crawl.

2. Xử lý dữ liệu với Spark

Tách ETL thành các job Raw → Bronze → Silver → Gold giúp dễ retry, debug và kiểm soát từng bước.

3. Xử lý luồng

Kafka, checkpoint, watermark và dead-letter giúp quản lý dữ liệu đến liên tục và phục hồi khi job restart.

4. Lưu trữ dữ liệu

JSONL phù hợp giữ dữ liệu gốc; Parquet và phân vùng phù hợp xử lý; Elasticsearch phục vụ dữ liệu cần truy vấn nhanh.

5. Điều phối hệ thống

Airflow, Kubernetes Job và Spark log giúp xác định bước lỗi và phân tích nguyên nhân trong pipeline.

6. Chất lượng dữ liệu và kiểm thử

Kiểm tra schema, loại trùng theo job_id, tách bản ghi lỗi và xác minh dữ liệu sau mỗi tầng xử lý.

THANK YOU !

Q&A
